




SABER PRO ANALYTICS: PREDICCIÓN Y SEGMENTACIÓN DE ESTUDIANTES

- Paula Andrea Velásquez
- Sergio Pardo
- Laura Beltrán
- Juan Pablo Arias





INTRODUCCIÓN

El proyecto busca desarrollar un modelo de aprendizaje de máquina que, a partir de variables sociales, económicas y académicas de estudiantes aspirantes o en proceso de ingreso a programas de educación superior

- Predecir el puntaje probable que obtendrán en las pruebas Saber Pro considerando factores sociales, económicos y académicos.
- Segmentar y clasificar grupos de estudiantes con el fin de identificar perfiles característicos según criterios como rendimiento, condiciones socioeconómicas y tipo de programa cursado.

Base de Datos

[Resultados únicos Saber Pro.](#)

2018 - 2022

Dimensión: 1,22 millones de registros, 57 variables.





Saber Pro Analytics


ELEVATOR PITCH



PREGUNTAS DE NEGOCIO Y DE ANÁLISIS



1. ¿Cuáles son los factores sociales, económicos y académicos que más inciden en el desempeño de los estudiantes en las pruebas Saber Pro?
2. ¿Cómo se pueden identificar y agrupar patrones o perfiles característicos de estudiantes según su rendimiento, condiciones socioeconómicas y tipo de programa cursado, utilizando técnicas de aprendizaje no supervisado?
3. ¿De qué manera pueden las universidades y entidades educativas diseñar políticas de admisión, acompañamiento académico y apoyo financiero para reducir el riesgo de bajo desempeño y potenciar el éxito estudiantil?



JUSTIFICACIÓN

Responder estas preguntas permite a las instituciones educativas pasar de un enfoque reactivo a uno preventivo. Al conocer los factores críticos y segmentar perfiles de estudiantes, se pueden diseñar estrategias de admisión, tutoría y financiamiento basadas en datos reales, optimizando recursos y mejorando los indicadores de retención y desempeño académico.



IMPORTANCIA DEL PROYECTO

1

Valor estratégico para la toma de decisiones

Las universidades que lo adopten podrán diseñar políticas de admisión, acompañamiento académico y retención basadas en evidencia, no en intuición.


Beneficio directo: decisiones más precisas que elevan la calidad académica y la reputación institucional, atrayendo más estudiantes y recursos.

2

Optimización y focalización de recursos

La propuesta permite asignar becas, apoyos financieros y programas de tutoría con alta precisión.

Beneficio directo: El presupuesto se invierte donde produce mayor impacto, reduciendo la deserción y mejorando los indicadores de graduación, un factor clave para la financiación estatal y la acreditación de alta calidad.



IMPORTANCIA DEL PROYECTO



3

Impulso a la excelencia y competitividad estudiantil

Abre oportunidades laborales y de posgrado para los estudiantes.

Beneficio directo: egresados más competitivos que elevan el prestigio de la universidad y aumentan su visibilidad internacional.

4

Innovación educativa basada en datos

La aplicación de machine learning, clustering y análisis predictivo moderniza la gestión académica y coloca a la institución a la vanguardia de la transformación digital en educación superior.

Beneficio directo: fortalece la imagen de la universidad como líder en innovación y referente en analítica educativa.

5

Impacto social y compromiso con la equidad

Al descubrir talento en contextos socioeconómicos desafiantes y anticipar riesgos de bajo desempeño, el modelo amplía el acceso a la educación superior de calidad y contribuye a reducir las brechas sociales.



Saber Pro Analytics

EDA



VARIABLES IRRELEVANTES

Primero se identificaron y eliminaron las variables que no aportaban información relevante para los objetivos del negocio o que simplemente no contenían datos útiles para el análisis. Algunas de ellas:






1. Identificadores o redundantes
 - **ESTU_TIPODOCUMENTO.**
2. Ubicación geográfica
 - Ejemplo: **departamentos** y **municipios**.
3. Sin valor analítico
 - Ejemplo: **ESTU_NIVEL_PRGM_ACADEMICO** = Solo se analiza Pregrado.
4. Variables redundantes
 - Ejemplo: **MOD_INGLES_DESEM** vs **MOD_INGLES_PUNT**.

Dimensión: 451.782 de registros, 25 variables.


MEDIDAS DE TENDENCIA CENTRAL

Estadístico	RAZONAMIENTO CUANTITATIVO	COMUNCIACION ESCRITA	LECTURA CRITICA	INGLES	COMPETENCIAS CIUDADANAS
Media	145,31	138,94	147,26	151,76	144,12
Desviación Estándar	31,87	42,22	30,64	33,50	33,32
mín	0	0	0	0	0
25%	122	123	125	130	121
50%	145	140	147	148	145
75%	167	164	169	172	168
max	300	300	300	300	300

MEDIDAS DE TENDENCIA CENTRAL




ANÁLISIS DE CORRELACIÓN






- Las competencias de Lectura Crítica y Competencias Ciudadanas muestran la relación más fuerte.
- El Módulo de Comunicación Escrita es el más independiente.
- En general, las correlaciones positivas entre módulos sugieren que existe un perfil de estudiante que rinde de forma consistente en varias áreas, aunque las magnitudes varían según la competencia.

Distribución Núcleo del pregrado




Distribución de Puntajes por Estrato Socioeconómico







Distribución: Estrato socioeconómico




Horas de trabajo semanales




¿Paga matrícula con beca?




¿Tiene crédito para pagar matrícula?




¿Los padres pagan la matrícula?




¿El estudiante paga la matrícula por sí mismo?





Distribución nivel de estudios del padre



Distribución nivel de estudios de la madre



VALORES ATÍPICOS



CALIDAD DE DATOS

- El dataset contiene 187k valores faltantes (**41%**), concentrados en variables socioeconómicas y familiares.
- Las variables clave (Modulos de conocimiento) no presentan nulos, lo que asegura confiabilidad en los resultados principales.
- La mayoría de variables tienen baja proporción de nulos (**<6%**), manejables con imputación simple o categorías adicionales.
- Existen valores atípicos fuera del rango intercuartílico. No obstante, esto responde a la propia naturaleza de la distribución (**normal**).
- En general, los datos presentan buena calidad para análisis, con retos puntuales en características familiares.



Saber Pro Analytics

INGENIERÍA DE CARACTERÍSTICAS



INGENIERÍA DE CARACTERÍSTICAS

1

PUNTAJE GLOBAL

Se calcula el puntaje global como la suma de los puntajes individuales de cada modulo dividido entre el total de modulos. Es decir un promedio de desempeño global

3

UNIFICACION DE VARIABLES

- PAGO_MATRICULA: integración de 4 columnas en una sola categórica.
- Prioridad: BECA → CRÉDITO → PADRES → PROPIO.

$$\frac{(\text{Libro}) + (\text{Calculadora}) + (\text{Globo}) + (\text{Lápiz}) + (\text{Hi})}{5}$$

Ejemplo:

	Módulo	Puntaje
	Lectura Crítica	226
	Razonamiento Cuantitativo	219
	Competencias Ciudadanas	201
	Comunicación Escrita	190
	Inglés	206

$$\frac{226 + 219 + 201 + 190 + 206}{5} = 208$$

 Puntaje global **208**

INGENIERÍA DE CARACTERÍSTICAS

TRANSFORMACIONES

2

- Carga laboral (ESTU_HORASSEMANATRABAJA) → Conversión de rangos a valores numéricos (0–30 horas).
- Matrícula (ESTU_VALORMATRICULAUNIVERSIDAD) → Extracción de valor máximo de los rangos (en millones).
- Estrato (FAMI ESTRATOVIVIENDA) → Conversión a enteros (1–6) y “Sin Estrato” = 0.
- Modalidad (ESTU_METODO_PRGM) → Unificación en dos categorías: Presencial y Distancia.


ESTANDARIZACION Y LIMPIEZA

4

- Se estandarizaron los niveles educativos en 7 categorías: Ninguno, Primaria, Bachillerato, Técnica, Profesional, Postgrado, No sabe.
- Se eliminaron filas con datos faltantes (mínimo impacto, 451 782 registros totales) para mantener integridad del dataset.
- Esta decisión mantiene la integridad del dataset y evita sesgos o distorsiones en los modelos de segmentación y predicción .

INGENIERÍA DE CARACTERÍSTICAS

El gráfico muestra una distribución aproximadamente normal, centrada alrededor de 150 puntos, lo que sugiere una dispersión equilibrada de los resultados y facilita su uso en modelos que asumen normalidad.





Saber Pro Analytics

MODELADO, EVALUACIÓN E INTERPRETACIÓN



PREDICCIÓN DEL PUNTAJE GLOBAL



- Se aplica one-hot encoding a todas las variables categóricas → 69 columnas finales, 419 809 registros.
- Dataset dividido en 80 % entrenamiento / 20 % prueba para aprender y evaluar el modelo de forma independiente.
- Optimización de hiperparámetros mediante RandomizedSearchCV.

Modelo	MSE (Test)	RMSE (Test)	MAE (Test)	R ² (Test)	Training Time (s)
LinearRegression RandomSearch	457,44	21,39	16,87	0,28	24,04
DecisionTree RandomizedSearch	457,97	21,4	16,82	0,28	34,08
RandomForest	444,62	21,09	16,61	0,30	1027,01
GradientBoosting	436,05	20,88	16,41	0,32	1289,4


CLUSTERIZACIÓN Y ANÁLISIS DE PERFILES

- **Objetivo**
 - Identificar perfiles con características socioeconómicas y académicas similares.
- **Método**
 - Elbow Method para determinar el número óptimo de clusters.
- **Evaluación**
 - Silhouette Score e Índice Davies–Bouldin para medir cohesión y separación.
- **Beneficio**
 - Complementa el análisis predictivo, facilitando segmentación y estrategias educativas.
- **pipeline de transformación que**
 - Imputa valores faltantes (mediana para numéricas, moda para categóricas).
 - Escala las variables numéricas.
 - Codifica las variables categóricas con One-Hot Encoding, descartando la primera categoría para evitar multicolinealidad.

CLUSTERIZACIÓN Y ANÁLISIS DE PERFILES



CLUSTERIZACIÓN Y ANÁLISIS DE PERFILES



EVALUACIÓN E INTERPRETACIÓN



Cluster 0 - Bajo puntaje, estrato bajo, modalidad a distancia, trabaja bastante

- Bajo puntaje (133.8).
- Estrato bajo (≈ 2).
- Trabajan más (≈ 26 h/sem).
- Modalidad distancia (56%).
- Matrícula: propio/crédito, poco apoyo de padres.

Cluster 1 - Alto puntaje, estrato medio-alto, presencial, trabaja menos

- Alto puntaje (166.0).
- Estrato medio-alto (≈ 3).
- Trabajan menos (≈ 16 h/sem).
- Modalidad presencial (89%).
- Matrícula: principalmente padres. Padres: mayor educación (profesional/postgrado).

EVALUACIÓN E INTERPRETACIÓN

Cluster 0 — Bajo puntaje, estrato bajo, modalidad a distancia, trabaja bastante


- Puntaje global más bajo (media 126.9)
- Estrato más bajo (media 1.91, mediana 2)
- Muchas horas de trabajo (media 24.9, mediana 30)
- Predominan programas a distancia (64.8%)
- Matrícula: más propio (36.1%) y crédito (32.9%), menos padres (14.5%)
- Educación de padres: alta primaria, muy bajo nivel profesional o postgrado

Cluster 1 — Medio puntaje, estrato medio, presencial, también trabaja bastante

- Puntaje global intermedio (media 157.5)
- Estrato medio (media 2.98, mediana 3)
- Muchas horas de trabajo (media 28.3, mediana 30)
- Mayormente presencial (74.8%)
- Matrícula: padres (29.3%) y crédito (30.2%) similares, propio 25.0%
- Educación de padres: intermedia, predominan bachillerato y algunos con profesional

Cluster 2 — Alto puntaje, estrato medio-alto, presencial, casi no trabaja, padres pagan


- Puntaje global más alto (media 163.4)
- Estrato más alto (media 3.19, mediana 3)
- Casi no trabajan (media 3.9, mediana 0)
- Fuertemente presencial (90.0%)
- Matrícula: principalmente padres (51.3%), poco propio (6.3%) y crédito (26.0%)
- Educación de padres: más alta, con mayor presencia de profesional y postgrado



PREGUNTAS DE NEGOCIO Y DE ANÁLISIS



1. ¿Cuáles son los factores sociales, económicos y académicos que más inciden en el desempeño de los estudiantes en las pruebas Saber Pro?
2. ¿Cómo se pueden identificar y agrupar patrones o perfiles característicos de estudiantes según su rendimiento, condiciones socioeconómicas y tipo de programa cursado, utilizando técnicas de aprendizaje no supervisado?
3. ¿De qué manera pueden las universidades y entidades educativas diseñar políticas de admisión, acompañamiento académico y apoyo financiero para reducir el riesgo de bajo desempeño y potenciar el éxito estudiantil?





PREGUNTAS

Saber Pro Analytics

JuanParias29/
SaberPro_Prediction_an...



Proyecto del curso de Técnicas de ML



1

Contributor



0

Issues



0

Stars



0

Forks



JuanParias29/SaberPro_Prediction_and_Profiling: Proyecto del curso de Técnicas de ML

Proyecto del curso de Técnicas de ML. Contribute to JuanParias29/SaberPro_Prediction_and_Profiling development by creating an account on GitHub.



GitHub

