





SABER PRO ANALYTICS: PREDICCIÓN Y SEGMENTACIÓN DE ESTUDIANTES

□ Paula Andrea Velásquez
□ Sergio Pardo
□ Laura Beltrán Arias
□ Juan Pablo Arias



ÍNDICE

- Introducción
- Elevator Pitch
- EDA
- Ingeniería de Características
- Modelado, Evaluación e Interpretación
- Preguntas





Saber Pro Analytics

INTRODUCCIÓN





INTRODUCCIÓN

El proyecto busca desarrollar un modelo de aprendizaje de máquina que, a partir de variables sociales, económicas y académicas de estudiantes aspirantes o en proceso de ingreso a programas de educación superior

- Predecir el puntaje probable que obtendrán en las pruebas Saber Pro considerando factores sociales, económicos y académicos.
- Segmentar y clasificar grupos de estudiantes con el fin de identificar perfiles característicos según criterios como rendimiento, condiciones socioeconómicas y tipo de programa cursado.

Base de Datos

[Resultados únicos Saber Pro.](#) 2018 - 2022

Dimensión: 1,22 millones de registros, 57 variables.





Saber Pro Analytics

ELEVATOR PITCH






ELEVATOR PITCH

Ofre

NO AQUÍ

- 1** Optimizar la atención médica de pacientes con condiciones crónicas mediante protocolos personalizados.
- 2** Reducir el ausentismo y los errores de programación en citas médicas.
- 3** Integrar automáticamente las políticas de cobertura y autorización de las aseguradoras.
- 4** Garantizar la trazabilidad y seguridad de la información médica.
- 5** Cumplir con normativas de privacidad y protección de datos (HIPAA, GDPR).
- 6** Facilitar el monitoreo de la efectividad de los protocolos y la adherencia al tratamiento.





Saber Pro Analytics

EDA



VARIABLES IRRELEVANTES

Primero se identificaron y eliminaron las variables que no aportaban información relevante para los objetivos del negocio o que simplemente no contenían datos útiles para el análisis. Algunas de ellas:


1. Identificadores o redundantes
 - **ESTU_TIPODOCUMENTO.**
2. Ubicación geográfica
 - Ejemplo: **departamentos** y **municipios.**
3. Sin valor analítico
 - Ejemplo: **INST_ORIGEN** = “Oficial - No oficial”.
4. Variables redundantes
 - Ejemplo: **MOD_INGLES_DESEM** vs **MOD_INGLES_PUNT.**

MEDIDAS DE TENDENCIA CENTRAL


Estadístico	RAZONAMIENTO CUANTITATIVO	COMUNCIACION ESCRITA	LECTURA CRITICA	INGLES	COMPETENCIAS CIUDADANAS
Media	145,31	138,94	147,26	151,76	144,12
Desviación Estándar	31,87	42,22	30,64	33,50	33,32
mín	0	0	0	0	0
25%	122	123	125	130	121
50%	145	140	147	148	145
75%	167	164	169	172	168
max	300	300	300	300	300

MEDIDAS DE TENDENCIA CENTRAL


MOD_LECTURA_CRITICA_PUNT




MOD_COMUNI_ESCRITA_PUNT




MOD_INGLES_PUNT




MOD_RAZONA_CUANTITAT_PUNT



MOD_COMPETEN_CIUADADA_PUNT




ANÁLISIS DE CORRELACIÓN






- Las competencias de Lectura Crítica y Competencias Ciudadanas muestran la relación más fuerte.
- El Módulo de Comunicación Escrita es el más independiente.
- En general, las correlaciones positivas entre módulos sugieren que existe un perfil de estudiante que rinde de forma consistente en varias áreas, aunque las magnitudes varían según la competencia.

Distribución Núcleo del pregrado




Distribución de Puntajes por Estrato Socioeconómico






Distribución: Estrato socioeconómico




Método del Codo (Inercia vs k)




100000 120000 140000 160000


ESTU_HORASSEMAMANATRABAJA




¿Paga matrícula con beca?




¿Tiene crédito para pagar matrícula?




¿Los padres pagan la matrícula?




¿El estudiante paga la matrícula por sí mismo?





Distribución nivel de estudios del padre



Distribución nivel de estudios de la madre



VALORES ATÍPICOS



CALIDAD DE DATOS

- El dataset contiene 187k valores faltantes, concentrados en variables socioeconómicas y familiares.
-
- Las variables clave (Modulos de conocimiento) no presentan nulos, lo que asegura confiabilidad en los resultados principales.
-
- La mayoría de variables tienen baja proporción de nulos (<6%), manejables con imputación simple o categorías adicionales.
-
- Existen valores atípicos fuera del rango intercuartílico. No obstante, esto responde a la propia naturaleza de la distribución (**normal**).
-
- En general, los datos presentan buena calidad para análisis, con retos puntuales en características familiares.



Saber Pro Analytics

INGENIERÍA DE CARACTERÍSTICAS



INGENIERÍA DE CARACTERÍSTICAS

1

PUNTAJE GLOBAL

Se calcula el puntaje global como la suma de los puntajes individuales de cada modulo dividido entre el total de modulos. Es decir un promedio de desempeño global

3

UNIFICACION DE VARIABLES

- PAGO_MATRICULA: integración de 4 columnas en una sola categórica.
- Prioridad: BECA → CRÉDITO → PADRES → PROPIO.

$$\frac{(\text{Libro}) + (\text{Calculadora}) + (\text{Globo}) + (\text{Lápiz}) + (\text{Hi})}{5}$$

Ejemplo:

	Módulo	Puntaje
	Lectura Crítica	226
	Razonamiento Cuantitativo	219
	Competencias Ciudadanas	201
	Comunicación Escrita	190
	Inglés	206

$$\frac{226 + 219 + 201 + 190 + 206}{5} = 208$$

 Puntaje global **208**

INGENIERÍA DE CARACTERÍSTICAS

TRANSFORMACIONES

2

- Carga laboral (ESTU_HORASSEMANATRABAJA) → Conversión de rangos a valores numéricos (0–30 horas).
- Matrícula (ESTU_VALORMATRICULAUNIVERSIDAD) → Extracción de valor máximo de los rangos (en millones).
- Estrato (FAMI ESTRATOVIVIENDA) → Conversión a enteros (1–6) y "Sin Estrato" = 0.
- Modalidad (ESTU_METODO_PRGM) → Unificación en dos categorías: Presencial y Distancia.
- Eliminación de variables → Removidas columnas irrelevantes o redundantes (ej. institución, periodo).


ESTANDARIZACION Y LIMPIEZA

4

- Se estandarizaron los niveles educativos en 7 categorías: Ninguno, Primaria, Bachillerato, Técnica, Profesional, Postgrado, No sabe.
- Se eliminaron filas con datos faltantes (mínimo impacto, 451782 registros totales) para mantener integridad del dataset.
- Esta decisión mantiene la integridad del dataset y evita sesgos o distorsiones en los modelos de segmentación y predicción.

INGENIERÍA DE CARACTERÍSTICAS

El gráfico muestra una distribución aproximadamente normal, centrada alrededor de 150 puntos, lo que sugiere una dispersión equilibrada de los resultados y facilita su uso en modelos que asumen normalidad.





Saber Pro Analytics

MODELADO, EVALUACIÓN E INTERPRETACIÓN



PREDICCIÓN DEL PUNTAJE GLOBAL



- Se aplica one-hot encoding a todas las variables categóricas → 69 columnas finales, 419 809 registros.
- Dataset dividido en 80% entrenamiento / 20% prueba para aprender y evaluar el modelo de forma independiente.
- Optimización de hiperparámetros mediante RandomizedSearchCV.

Modelo	MSE (Test)	RMSE (Test)	MAE (Test)	R ² (Test)	Training Time (s)
LinearRegression RandomSearch	457,44	21,39	16,87	0,28	24,04
DecisionTree RandomizedSearch	457,97	21,4	16,82	0,28	34,08
RandomForest	444,62	21,09	16,61	0,30	1027,01
GradientBoosting	436,05	20,88	16,41	0,32	1289,4


CLUSTERIZACIÓN Y ANÁLISIS DE PERFILES

- **Objetivo**
 - Identificar perfiles con características socioeconómicas y académicas similares.
- **Método**
 - Elbow Method para determinar el número óptimo de clusters.
- **Evaluación**
 - Silhouette Score e Índice Davies–Bouldin para medir cohesión y separación.
- **Beneficio**
 - Complementa el análisis predictivo, facilitando segmentación y estrategias educativas.
- **pipeline de transformación que**
 - Imputa valores faltantes (mediana para numéricas, moda para categóricas).
 - Escala las variables numéricas.
 - Codifica las variables categóricas con One-Hot Encoding, descartando la primera categoría para evitar multicolinealidad.


CLUSTERIZACIÓN Y ANÁLISIS DE PERFILES



CLUSTERIZACIÓN Y ANÁLISIS DE PERFILES



EVALUACIÓN E INTERPRETACIÓN





TÉCNICAS DE APRENDIZAJE DE MÁQUINA

PREGUNTAS